

ERICK ECKERMANN CARDOSO

RELATÓRIO TCC1 - GERAÇÃO DE DADOS SINTÉTICOS PARA CLASSIFICAÇÃO DE  
OCUPAÇÃO DE VAGAS DE ESTACIONAMENTO

*(versão pré-defesa, compilada em 13 de dezembro de 2023)*

Relatório apresentado como requisito à conclusão da disciplina TCC1 no Curso de Bacharelado em Ciência da Computação, Setor de Ciências Exatas, da Universidade Federal do Paraná.

Área de concentração: *Ciência da Computação*.

Orientador: Paulo R. Lisboa de Almeida.

CURITIBA PR

2023

## 1 INTRODUÇÃO

Nos últimos anos, o crescimento urbano acelerado e a expansão cada vez maior da frota de veículos nas estradas têm colocado em foco a urgência de uma gestão de estacionamento eficiente para as autoridades municipais e os gestores de infraestruturas urbanas. A busca por soluções inovadoras que otimizem o uso desses espaços, oferecendo comodidade aos motoristas, reduzindo congestionamentos e minimizando o impacto ambiental, tem sido alvo de extensas pesquisas. Nesse contexto, a implementação de técnicas de visão computacional e aprendizado de máquina se destaca como uma abordagem promissora para aprimorar a gestão de estacionamento(?).

Um dos principais desafios na administração de estacionamento reside na identificação e classificação das vagas como ocupadas ou livres. Existem algumas abordagens para realizar essa tarefa, como a utilização de sensores instalados em cada vaga para determinar sua ocupação ou o uso de câmeras de monitoramento estrategicamente posicionadas para o reconhecimento e classificação das vagas por meio das imagens captadas pelas câmeras. Esta última alternativa se destaca pela sua viabilidade, pois é uma alternativa de baixo custo e tempo de implementação, e portanto será o foco desse trabalho.

Os modelos de classificação em aprendizado de máquina demandam conjuntos de dados de treinamento com qualidade, diversidade e representatividade do mundo real. Contudo, a coleta desses dados é uma tarefa complexa e dispendiosa, requerendo tempo, recursos financeiros e enfrentando desafios na rotulagem dos dados coletados, além de questões de privacidade. A comunidade acadêmica disponibiliza alguns conjuntos de dados que podem ser usados para o problema de classificação de vagas, como é o caso da PkLot(Almeida et al., 2013) e CNRPark-EXT(Amato et al., 2016), que contrinuem significativamente para as pesquisas nessa área. No entanto, dado que é um problema em evolução contínua, a necessidade de novos dados para treinamento e validação de modelos permanece constante.

Neste trabalho, propõe-se a utilização de dados sintéticos como forma de sobrepujar os desafios existentes no uso de dados reais. Os dados gerados sinteticamente serão utilizados no treinamento de modelos de classificação com a finalidade de classificar vagas de estacionamento. Dados sintéticos são dados gerados de forma artificial e algorítmica, assemelhando-se aos dados reais, embora não derivem de observações diretas ou coletas reais. Isso possibilita superar alguns desafios associados à coleta de dados reais, permitindo a criação de conjuntos de dados volumosos, com maior variedade e a um custo reduzido, em um período de tempo menor.

Diversas ferramentas podem ser empregadas para gerar dados sintéticos. Neste trabalho será utilizado o motor gráfico Unity3D e seu pacote voltado para visão computacional, o Unity-perception (Borkman et al., 2017). Será adotada uma Rede Neural Convolucional (CNN) e utilizado o processo de transfer-learning, utilizando a MobileNetv2 como modelo base, para o

treinamento com os dados sintéticos gerados, validando sua acurácia por meio de testes com imagens dos conjuntos de dados PkLot e CNRPark.

## 2 ESTADO DA ARTE

Técnicas e modelos de aprendizado de máquina são amplamente utilizados hoje em dia nos mais diversos problemas, por conta disso, existe uma grande quantidade de base de dados disponíveis para o treinamento de modelos, dos mais diversos tipos. Entretanto, mesmo com as bases de dados disponíveis atualmente, o problema de classificação de vagas de estacionamento ainda é um problema em aberto (de Almeida et al., 2022). Tanto este quanto diversos outros problemas ainda possuem uma certa carência de dados, por isso um crescente interesse na geração e uso de dados sintéticos tem sido notado. Neste capítulo serão discutidos os métodos atuais de machine learning para classificação de vagas de estacionamento e também como são gerados os dados sintéticos hoje em dia e quais os resultados obtidos.

### 2.1 CLASSIFICAÇÃO DE VAGAS

#### 2.1.1 Conjuntos de dados

##### 2.1.1.1 *PkLot*

O conjunto de dados PKLot (de Almeida et al., 2015) é uma base comumente usada para pesquisa em detecção de vagas de estacionamento por meio de visão computacional. O PKLot contém imagens de diferentes estacionamentos capturadas por câmeras posicionadas em várias alturas e ângulos, registrando condições variadas de iluminação, clima e ocupação de vagas. As imagens são categorizadas em dois grupos principais: ocupadas e livres. Cada imagem está associada a um rótulo indicando se a vaga de estacionamento está ocupada ou desocupada.

O PKLot oferece uma gama diversificada de desafios para algoritmos de detecção de vagas de estacionamento, abrangendo diferentes situações e cenários do mundo real. Essa diversidade é valiosa para treinar e avaliar algoritmos de aprendizado de máquina e visão computacional, permitindo o desenvolvimento de sistemas robustos capazes de identificar automaticamente a ocupação de vagas em estacionamentos com base nas imagens fornecidas.

##### 2.1.1.2 *CNRPark-EXT*

O CNRPark-EXT (Amato et al., 2016) é um conjunto de dados usado para pesquisas na área de detecção de ocupação de vagas de estacionamento por meio de técnicas de visão computacional. Especificamente, é uma expansão do conjunto de dados CNRPark, que foi desenvolvido para avaliar algoritmos de reconhecimento de ocupação de vagas em estacionamentos.

É composto por imagens capturadas por câmeras instaladas em 9 diferentes ambientes de estacionamento. Essas imagens apresentam variações em iluminação, condições climáticas e diferentes ângulos de visualização, tornando o conjunto de dados desafiador e representativo de

situações do mundo real. Ele é utilizado para treinar e avaliar modelos de machine learning e algoritmos de visão computacional, visando classificar automaticamente vagas de estacionamento como ocupadas ou livres.

## 2.1.2 Métodos de classificação

### 2.1.2.1 Baseados em extração de características

Métodos de classificação baseados em extração de características são técnicas fundamentais em aprendizado de máquina, focadas em identificar atributos relevantes a partir dos dados originais. Essas características, obtidas por meio de análises estatísticas, transformações de dados ou descrições visuais, procuram capturar informações cruciais para diferenciar e classificar padrões ou objetos. Após a extração, algoritmos de classificação, como Support Vector Machine (SVM), Multilayer Perceptron (MLP), e outros, são treinados, utilizando as características selecionadas como base para a tomada de decisão.

O trabalho de Almeida et al. (2013) propõe o uso de características LPQ e LBP extraídas das imagens como vetores de características e SVMs como classificadores. Neste trabalho, a primeira versão da base de dados PKLot foi introduzida. O trabalho e a base de dados foram expandidos em Almeida et al. (2015), onde a base de dados PKLot completa foi disponibilizada. Conjuntos de SVMs treinados utilizando diversas variações dos métodos LPQ/LBP como características foram utilizados para classificação.

Este método resultou em desempenhos satisfatórios, contudo revelou limitações em termos de generalização. Em geral, ao treinar um classificador com um subconjunto de imagens de um determinado estacionamento e testá-lo com outro subconjunto do mesmo estacionamento, alcançamos consistentemente uma acurácia média de aproximadamente 99,5%, praticamente atingindo 100%. No entanto, ao treinar o modelo com um conjunto de imagens de um estacionamento específico e testá-lo com imagens de outros estacionamentos, a acurácia média caiu para cerca de 85%. Essa redução na precisão ao lidar com dados de estacionamentos distintos sugere que o método pode ser eficaz dentro do mesmo contexto de estacionamento, mas enfrenta dificuldades na generalização para diferentes ambientes ou cenários.

### 2.1.2.2 Redes Neurais Convolucionais (CNN)

Uma aplicação de Redes Neurais Convolucionais (CNN) na classificação de vagas de estacionamento foi introduzida em Amato et al.(2016). Os pesquisadores desenvolveram a rede mAlexNet, modelada a partir da estrutura da AlexNet, e realizaram experimentos utilizando o conjunto de dados CNRPark. Este estudo empregou a versão expandida do conjunto de dados, CNRPark-EXT, para treinamento e teste, além da utilização da base de dados PKLot. A rede mAlexNet demonstrou habilidade para lidar com as variações presentes nos estacionamentos e diferentes ângulos de câmera, mantendo pequenas reduções na precisão em vários cenários.

## 2.2 GERAÇÃO DE DADOS SINTÉTICOS

Os dados sintéticos são gerados artificialmente e algorítimicamente e são empregados no treinamento de modelos de machine learning para complementar conjuntos de dados existentes ou compensar a falta de dados reais. Eles desempenham um papel crucial ao aumentar a diversidade e a quantidade de amostras disponíveis, especialmente em cenários onde os conjuntos de dados são limitados ou insuficientes. Além disso, esses dados podem ser úteis na representação de situações raras, na preservação da privacidade dos dados reais, na redução de vieses nos conjuntos de dados e na criação de cenários de teste e validação para garantir a robustez dos modelos de machine learning.

Diversas ferramentas podem ser utilizadas para a geração de dados sintéticos. Com relação a imagens sintéticas, as ferramentas mais utilizadas são motores gráficos e engines de jogos como Unity e Unreal Engine. Dando destaque às engines de jogos, existem pacotes personalizados que auxiliam na aleatorização, captura e rotulação dos dados, como é o caso do Unity perception (Borkman et al., 2017), para o Unity3d, e o NDDS(To et al., 2018) para a Unreal Engine 4.

Entretanto, existem algumas barreiras quando se trata de utilizar dados sintéticos para treinamento. O "Reality Gap", conhecido como a lacuna entre ambientes sintéticos e a complexidade do mundo real, resulta na dificuldade dos modelos treinados apenas com dados sintéticos em se adaptarem adequadamente a situações reais. Essa discrepância surge devido à complexidade em simular fielmente todas as características visuais, físicas e dinâmicas do mundo real nos dados sintéticos. Elementos como iluminação, texturas, variações climáticas e interações complexas são desafios para a reprodução precisa. Consequentemente, modelos treinados exclusivamente com dados sintéticos podem ter dificuldade em generalizar para situações reais. Uma estratégia para superar essa limitação é combinar dados sintéticos e reais durante o treinamento, oferecendo ao modelo uma exposição mais diversificada e possibilitando uma melhor adaptação e desempenho em cenários do mundo real. Outras técnicas também estão presentes na literatura.

### 2.2.1 Domain Randomization

O conceito de domain-randomization (Tobin et al., 2021), envolve introduzir aleatoriedade deliberada nos ambientes de treinamento sintéticos usados para ensinar modelos de machine learning, principalmente com imagens. Essa técnica visa criar uma variedade maior de cenários, ajustando aleatoriamente parâmetros como texturas, iluminação e formas geométricas. Ao variar aleatoriamente as características do ambiente virtual os modelos são expostos a uma ampla gama de condições durante o treinamento. Essa diversidade ajuda os modelos a se adaptarem a diferentes variações que podem ser encontradas no mundo real, capacitando-os a generalizar de forma mais eficaz para situações reais. Em essência, ao simular uma maior variedade de cenários durante o treinamento, os modelos se tornam mais robustos e capazes de lidar com a

complexidade e as variações do mundo real, diminuindo a diferença entre os ambientes virtuais e o mundo real.

O estudo de Tobin et al.(2021) demonstrou que um detector de objetos treinado exclusivamente em simulação utilizando a técnica de domain randomization pode atingir uma precisão suficientemente alta no mundo real, possibilitando a realização de agarramentos em ambientes com obstáculos.

### 2.2.2 Combinação de imagens fotorealísticas e Domain Randomization

Em Tremblay et al.(2018) foi demonstrado que a combinação de imagens sintéticas não fotorealistas (Domain Randomization) com imagens sintéticas fotorealistas, para o treinamento de redes neurais, supera com sucesso o problema de reality-gap para aplicações no mundo real, alcançando desempenho comparável com redes de última geração treinadas em dados reais.

A combinação de imagens fotorealísticas e domain randomization no treinamento de modelos de deep learning é eficiente porque atenua a diferença entre ambientes sintéticos e o mundo real. Enquanto as imagens fotorealísticas replicam detalhes visuais precisos do mundo real, o domain randomization introduz variações controladas ou aleatórias nos ambientes virtuais. Essa abordagem amplia a diversidade dos dados de treinamento, permitindo que os modelos se adaptem a uma variedade de condições presentes na prática, fortalecendo sua capacidade de generalização para situações reais ao minimizar a lacuna da realidade durante o treinamento.

### 3 PROPOSTA

O objetivo deste trabalho é explorar o potencial dos dados sintéticos para o treinamento de modelos de classificação visando a classificação precisa do status das vagas de estacionamento, entre ocupada ou livre. Essa proposta visa superar os desafios enfrentados na obtenção de conjuntos de imagens de treinamento com qualidade, diversidade e representatividade do mundo real para modelos de aprendizado de máquina. Além disso, planeja-se investigar como a utilização de dados sintéticos pode ser uma alternativa viável e eficaz para aprimorar as tarefas relacionadas a gestão de estacionamentos, oferecendo uma solução economicamente viável, eficiente e de baixo custo em comparação com a coleta de dados reais.

#### 3.1 DADOS E CLASSIFICAÇÃO

Nesta seção será apresentada a proposta com relação à geração das imagens sintéticas e o modelo de classificação de aprendizado de máquina utilizado.

##### 3.1.1 Geração das imagens sintéticas

Para a geração das imagens sintéticas, planeja-se utilizar técnicas de geração de imagens sintéticas, simulando ambientes de estacionamento por meio do motor gráfico Unity3D e seu pacote de visão computacional, o Unity-perception (Borkman et al., 2017). Esse pacote permite a aleatorização do ambiente 3D com mudanças nas posições dos carros, posições das de obstáculo como árvores, aleatorização de texturas, intensidade e posição da luz, etc. Além disso as imagens serão geradas já com as informações para recorte das vagas de estacionamento e seus respectivos rótulos, como ocupadas ou livres, poupando assim o esforço de rotulação manual.

Nesse ambiente 3D os parâmetros da câmera (Posição e angulação) serão estimados e replicados utilizando o programa OpenSource fSpy (Stuffmatic, 2023), a fim de produzir imagens sintéticas com características semelhantes as reais. Essa ferramenta possibilitará a estimação dos parâmetros da câmera de forma simples, traçando quatro linhas que indicam os pontos focais da imagem, o que pode aumentar a acurácia do modelo com menor trabalho. A estimação da câmera será feita para cada um dos estacionamentos presentes no conjunto de dados PkLot (de Almeida et al., 2015), ou seja, PUCPR, UFPR04 e UFPR05. Com isso serão produzidos dois conjuntos de imagens sintéticas para cada parâmetro estimado:

- Domain Randomization: Imagens sintéticas do estacionamento utilizando a técnica proposta em Tobin et al.(2021)
- Imagens sintéticas fotorealísticas: Imagens com uma qualidade de renderização maior, buscando simular de forma fiel as características presentes nas imagens reais



### 3.1.2 Modelo classificação

Será adotada uma abordagem centrada em Redes Neurais Convolucionais (CNN) e na estratégia de transfer-learning, onde a MobileNetv2 será utilizada como modelo base. Esta abordagem se baseia na premissa de que um modelo treinado em um conjunto de dados amplo e representativo pode atuar como um modelo genérico eficaz. Durante o processo, a camada de classificação será removida e as camadas anteriores serão congeladas para preservar seus pesos durante o treinamento, desempenhando o papel de extratores de características. Posteriormente, será adicionada uma nova camada de classificação, a qual será treinada com os dados específicos desejados, adaptando assim o modelo pré-treinado para a tarefa específica de classificação das vagas como ocupadas ou livres.

## 3.2 PROTOCOLO EXPERIMENTAL PROPOSTO

Esta seção descreve como serão divididas as bases de dados entre conjunto de treino e teste, bem como o protocolo de validação e experimentos propostos para a validação dos modelos treinados.

### 3.2.1 Divisão em conjuntos de treino e teste

Serão treinados modelos utilizando tanto imagens reais disponíveis no conjunto de dados PkLot quanto suas versões sintéticas. As imagens sintéticas foram geradas aplicando os parâmetros estimados da câmera de cada estacionamento do PkLot em um ambiente 3D.

No caso dos conjuntos da PkLot, será empregada a estratégia proposta no trabalho de Almeida et al. (2015), que determina que imagens do mesmo dia devem pertencer exclusivamente a um dos conjuntos, seja de treinamento ou de teste. Para cada estacionamento, as imagens serão divididas na proporção de 50% para treinamento e teste, respeitando essa restrição.

Os dados sintéticos serão exclusivamente utilizados no treinamento dos modelos, não sendo necessário dividir esses conjuntos de dados gerados. Portanto, os seguintes conjuntos de dados estarão disponíveis:

- UFPR04 - Treino e Teste
- UFPR04 sintético randomizado (Domain Randomization)
- UFPR04 sintético fotorealista
- UFPR05 - Treino e Teste
- UFPR05 sintético randomizado (Domain Randomization)
- UFPR05 sintético fotorealista
- PUCPR - Treino e Teste

- PUCPR sintético randomizado (Domain Randomization)
- PUCPR sintético fotorealista

### 3.2.2 Experimentos

Cada conjunto de imagens disponível e separado na etapa de divisão dos conjuntos de dados será alocado para o treinamento de um modelo específico. Os conjuntos de imagens sintéticas serão integralmente empregados como conjuntos de treinamento. No processo de validação durante o treinamento, serão utilizadas imagens do estacionamento real correspondente.

A métrica de comparação principal será a acurácia simples. Nesse contexto, a predição será realizada em um conjunto de dados rotulados, seguida pelo cálculo da taxa de acertos, baseando-se nos rótulos originais de cada imagem. Os testes serão conduzidas, para um determinado modelo, da seguinte forma:

- Teste com o subconjunto de Testes UFPR04
- Teste com o subconjunto de Testes UFPR05
- Teste com o subconjunto de Testes PUCPR
- Teste com o conjunto de dados CNRPark-A
- Teste com o conjunto de dados CNRPark-B

Essa análise comparativa permitirá avaliar a performance dos modelos em diferentes condições de treinamento, destacando as variações de desempenho entre modelos treinados com dados reais e os gerados sinteticamente, seja de forma aleatória ou fotorealista.

## 4 RESULTADOS

Nesta sessão serão apresentados e discutidos os resultados dos experimentos propostos na sessão 3.

### 4.1 EXECUÇÕES

A tabela 4.1 mostra os resultados dos experimentos tendo como base o estacionamento UFPR04. Pode-se ver que no geral o modelo apresentou bons resultados tanto para os dados sintéticos como para os reais, tendo uma acurácia acima de 0.95 na maioria dos casos. Porém sua melhor performance fica evidente com o modelo treinado com os dados realistas, que alcançou uma acurácia excelente de em média 0.99 com os estacionamentos da PkLot, mostrando a capacidade de generalização do modelo treinado com dados reais. Os modelos treinados com dados sintéticos se mantiveram numa média de acurácia de 0.95, o que é um bom resultado, mesmo não alcançando a performance do modelo treinado com dados reais.

Tabela 4.1: Resultados UFPR04

Conjunto Treino	Conjunto Teste	Acurácia	Loss
UFPR04	UFPR04	<b>0.9973784685134888</b>	<b>0.00744111975654959</b>
	UFPR05	0.992316206073761	0.026203461998701096
	PUCPR	0.9913341999053955	0.03602888807654381
	CNRPark-A	0.9787716865539551	0.07389025390148163
	CNRPark-B	0.8300327658653259	0.7406405806541443
UFPR04 sintético randomizado	UFPR04	0.9643054008483887	0.17444078624248505
	UFPR05	0.947799563407898	0.2021385282278061
	PUCPR	<b>0.9684255123138428</b>	0.14903266727924347
	CNRPark-A	0.9554367065429688	<b>0.11254721879959106</b>
	CNRPark-B	0.7871510982513428	0.4944949746131897
UFPR04 sintético fotorealista	UFPR04	0.9548830986022949	0.24915337562561035
	UFPR05	0.9618846774101257	0.22398780286312103
	PUCPR	<b>0.9699152708053589</b>	0.2288242131471634
	CNRPark-A	0.9530059695243835	<b>0.1626977175474167</b>
	CNRPark-B	0.6970216631889343	0.5185118317604065

As tabelas 4.2 e 4.3 mostram os resultados dos experimentos tendo como base os estacionamentos UFPR05 e PUCPR, respectivamente. Pode-se notar que os resultados da PUCPR são semelhantes aos da UFPR04 tanto para os dados reais como os conjuntos gerados sinteticamente, se mantendo numa acurácia de em média 0.98 com o modelo treinado com dados reais e 0.96 com o modelo treinado com dados sintéticos. Podemos notar também a boa capacidade de generalização, já que o modelo treinado apenas com o subconjunto PUCPR apresentou resultados muito bons em todos os outros, salvo CNRPark-B. Já os resultados com os

modelos sintéticos da UFPR05 apresentaram resultados piores do que o geral, tendo uma média de acurácia de 0.75, mas mantevesse com resultados igualmente satisfatório aos outros, com relação ao modelo treinado com as imagens reais.

Tabela 4.2: Resultados UFPR05

Conjunto Treino	Conjunto Teste	Acurácia	Loss
UFPR05	UFPR04	0.9930852651596069	0.02502281218767166
	UFPR05	<b>0.9960375428199768</b>	<b>0.01266891323029995</b>
	PUCPR	0.9834603071212769	0.06736186891794205
	CNRPark-A	0.9630529880523682	0.09921148419380188
	CNRPark-B	0.7893341779708862	0.8512572646141052
UFPR05 sintético randomizado	UFPR04	0.6991318464279175	0.67948979139328
	UFPR05	0.7014817595481873	0.6748328804969788
	PUCPR	0.7480219006538391	0.6681806445121765
	CNRPark-A	<b>0.9649975895881653</b>	<b>0.14781269431114197</b>
	CNRPark-B	0.8379853367805481	0.4422059655189514
UFPR05 sintético fotorealista	UFPR04	0.7719458341598511	0.557625949382782
	UFPR05	0.8048615455627441	0.488942414522171
	PUCPR	0.8372944593429565	0.4830848276615143
	CNRPark-A	<b>0.9350186586380005</b>	<b>0.22728793323040009</b>
	CNRPark-B	0.7784188389778137	0.44967198371887207

Tabela 4.3: Resultados PUCPR

Conjunto Treino	Conjunto Teste	Acurácia	Loss
PUCPR	UFPR04	0.9933891892433167	0.01860688626766205
	UFPR05	0.9871246814727783	0.04195189103484154
	PUCPR	<b>0.9986397624015808</b>	<b>0.00746541703119874</b>
	CNRPark-A	0.9763409495353699	0.05127578601241112
	CNRPark-B	0.7165133357048035	1.0377250909805298
PUCPR sintético randomizado	UFPR04	<b>0.9806804656982422</b>	<b>0.08626607060432434</b>
	UFPR05	0.971541166305542	0.1300220787525177
	PUCPR	0.9699800610542297	0.10714691877365112
	CNRPark-A	0.9570571780204773	0.08663547039031982
	CNRPark-B	0.8064868450164795	0.5178163051605225

Em geral, todos os testes tiveram resultados não tão satisfatórios quando testados no conjunto CNRPark-B. Isso pode ser causado devido os problemas desse conjunto, que envolvem uma má qualidade da imagem e considerável oclusão na maior parte das imagens. Também podemos dizer que a angulação da câmera não pareceu fazer tanta diferença nos resultados dos modelos treinados inteiramente com dados sintéticos, pois as melhores acurácias não corresponderam aos conjuntos de dados respectivos aos parâmetros do estacionamento estimado.

## REFERÊNCIAS

- Almeida, P., Oliveira, L. S., Silva, E., Britto, A. e Koerich, A. (2013). Parking space detection using textural descriptors. Em *2013 IEEE International Conference on Systems, Man, and Cybernetics*, Manchester, UK.
- Amato, G., Carrara, F., Falchi, F., Gennaro, C., Meghini, C. e Vairo, C. (2016). Deep learning for decentralized parking lot occupancy detection. *Expert Systems with Applications - Elsevier*, 72:327–334. Invited paper.
- Borkman, S., Crespi, A., Dhakad, S., Ganguly, S., Hogins, J., Jhang, Y.-C., Kamalzadeh, M., Li, B., Leal, S., Parisi, P., Romero, C., Smith, W., Thaman, A., Warren, S. e Yadav, N. (2017). Unity perception: Generate synthetic data for computer vision. Em *2017 IEEE/RSJ International Conference on Intelligent Robots and Systems (IROS)*, Vancouver, BC, Canada.
- de Almeida, P. R., Oliveira, L. S., Jr., A. S. B., Jr., E. J. S. e Koerich, A. L. (2015). Pklot - a robust dataset for parking lot classification. *Expert Systems with Applications - Elsevier*, 42:4937–4949. Invited paper.
- de Almeida, P. R. L., Alves, J. H., Parpinelli, R. S. e Barddal, J. P. (2022). A systematic review on computer vision-based parking lot management applied on public datasets. *Expert Systems with Applications - Elsevier*, 198:957–4949. Invited paper.
- Stuffmatic (2023). fspy - open source still image camera matching. <https://fspy.io/>. Acessado em 12/12/2023.
- To, T., Tremblay, J., McKay, D., Yamaguchi, Y., Leung, K., Balanon, A., Cheng, J., e Birch-field., S. (2018). Ndds: Nvidia deep learning dataset synthesizer,. [https://github.com/NVIDIA/Dataset\\_Synthesizer](https://github.com/NVIDIA/Dataset_Synthesizer). Acessado em 07/12/2023.
- Tobin, J., Fong, R., Ray, A., Schneider, J., Zaremba, W. e Abbeel, P. (2021). Domain randomization for transferring deep neural networks from simulation to the real world. Em *arXiv:2107.04259 [cs.CV]*.